



CONTROLE PREDITIVO BASEADO EM PIRNN PARA PREVENÇÃO DO SURGE DE SISTEMAS DE COMPRESSÃO DE GÁS NATURAL

G. S. FREIRE^{1,2}, M. MARINHO^{1,2}, R. L. MEIRA^{1,2}, L. S. de SOUZA^{1,2}, D. D. SANTANA^{1,2}, M. A. F. MARTINS^{1,2}

¹ Universidade Federal da Bahia, Escola Politécnica, Departamento de Engenharia Química

² Programa de Recursos Humanos para Monitoramento Inteligente, Controle Avançado e Otimização Econômica para Campos de Petróleo e Gás - PRH 35.1

E-mail para contato: guilhermefreire@ufba.br

RESUMO-Este trabalho propõe o uso de uma Rede Neural Recursiva Fisicamente Informada (PIRNN) para representar o modelo no projeto de controle preditivo de sistemas de compressão de gás natural. O modelo PIRNN combina Redes Neurais Fisicamente Informadas (PINNs) e Redes Neurais Recorrentes (RNNs) para acelerar previsões. O controlador MPC com PIRNN foi até 8.65 vezes mais rápido que o NMPC tradicional, encontrando solução dentro do tempo de amostragem, mostrando um potencial de aplicação com desempenho similar ao de um NMPC.

1 INTRODUÇÃO

Sistemas de compressão de gás natural são fundamentais para o funcionamento da indústria petrolífera mundial, pois permitem o rápido escoamento do gás em redes de distribuição. No Brasil, essa função é ainda mais relevante devido à vasta extensão territorial do país. No entanto, a modelagem e o controle desses sistemas representam um grande desafio, pois a solução de um modelo fenomenológico pode levar mais tempo do que o exigido pelo sistema de controle, tornando inviável o tempo de cálculo da lei de controle.

Nesse cenário, as Redes Neurais Artificiais (RNAs) surgem como alternativa promissora, ao proporcionarem previsões rápidas e eficazes com base apenas em dados operacionais. Isso é vantajoso em processos ainda não modelados fenomenologicamente ou com baixa confiabilidade, como demonstrado por Nascimento, Giudici e Guardani (2000), que utilizaram dados experimentais e modelos fenomenológicos para o treinamento da RNA.

O uso de RNAs como modelos de controle preditivo já possui respaldo e aplicações consolidadas na indústria, conforme demonstrado por Draeger, Engell e Ranke (1995). A tese de Meira (2022), que aplica MPC na distribuição de gás natural, indica que esse setor já adota a abordagem preditiva, viabilizando o uso de RNAs como modelo de MPC.

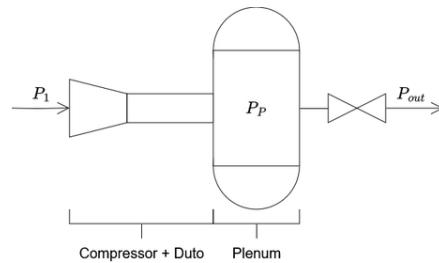
Este trabalho propõe avaliar a aplicação de RNAs como modelo de um controlador preditivo (MPC) voltado à prevenção do surge em sistemas de compressão de gás natural. Os resultados obtidos serão comparados com os de um controlador MPC não linear (NMPC) tradicional.



2 SISTEMA

O sistema de compressão em estudo é composto por um compressor centrífugo, um duto e um plenum, conforme detalha a Figura 1.

Figura 1: Sistema de Compressão.



As equações comumente adotadas na literatura para esse sistema, baseadas no momento angular axial, no balanço de momento do duto e na combinação do balanço de momentum e energia do plenum, são respectivamente (MEIRA et al., 2022):

$$\frac{d\dot{m}}{dt} = \frac{A_1}{L_C} (\phi(N(t), \dot{m}) P_1 - P_P(t)), \quad (1)$$

$$\frac{dP_P}{dt} = \frac{C_1^2}{v_P} (\dot{m}(t) - \alpha(t) K_v \sqrt{P_P - P_{out}}), \quad (2)$$

em que, \dot{m} , a vazão mássica do compressor, P_P , a pressão do plenum, são as variáveis controladas do sistema. N , a velocidade de rotacional do compressor, e α , a abertura da válvula, são as variáveis manipuladas. ϕ é a razão entre as pressões de entrada e saída do compressor, definida como uma função de \dot{m} e N , P_1 é a pressão de entrada do compressor, P_{out} é a pressão de saída da válvula, K_v é o coeficiente da válvula, A_1 é a área do duto, L_C é o comprimento do duto, v_P é o volume do plenum e C_1 é a velocidade do som no gás de entrada. A Tabela 1 apresenta os valores e as unidades das constantes do sistema.

Tabela 1: Tabela de variáveis.

Variável	A_1	v_P	L_C	C_1	K_v	P_1	P_{out}
Valor	$2.6 \cdot 10^{-3}$	2.0	2.0	479	0.38	4.5	5.0
Unidade	m^2	m^3	m	$\frac{m}{s}$	$\frac{kg}{s(kPa)^{0.5}}$	MPa	MPa

3 ARQUITETURA DA RNA

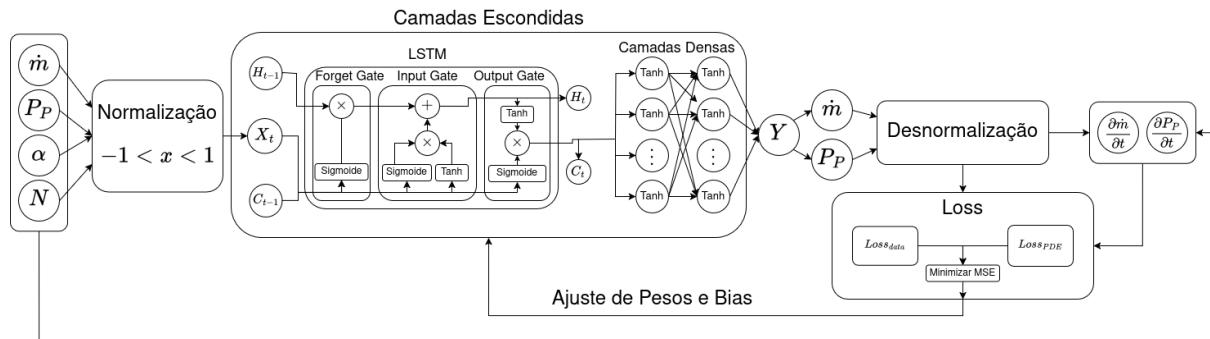
Para acelerar a previsão do comportamento do sistema em relação aos métodos numéricos tradicionais, foi desenvolvida uma arquitetura de RNA chamada PIRNN - uma Rede Neural Recorrente Fisicamente Informada.

A PIRNN utiliza três passos anteriores no tempo para realizar previsões e se retroalimenta com suas próprias saídas, simulando a dinâmica do sistema em intervalos de 0.5 s, que correspondem ao tempo amostral. Sua arquitetura é composta por uma camada de normalização



para o intervalo $[-1, 1]$, uma LSTM para capturar dependências temporais, duas camadas densas para lidar com a não linearidade do sistema e uma camada final de desnortinalização, conforme ilustrado na Figura 2.

Figura 2: Arquitetura PIRNN.



Durante o treinamento, a função de perda considerou a diferença entre os dados reais e preditos, além da diferença entre a resposta do modelo fenomenológico e a saída da PIRNN. O treinamento buscou minimizar o erro quadrático médio (MSE) ajustando os pesos e vieses das camadas ocultas com o otimizador Adam.

4 RNN-MPC

O Controlador Preditivo baseado em Modelo de Rede Neural Recursiva (RNN-MPC) utiliza como modelo interno a PIRNN desenvolvida neste trabalho. Essa rede é responsável por prever o comportamento futuro das variáveis controladas do sistema. Com base nessas previsões, o controlador calcula os incrementos ideais nas variáveis manipuladas para que as saídas alcancem os valores de referência desejados. O controlador procura resolver o seguinte problema de otimização:

$$\min_{\Delta \mathbf{u}_k} V_k = \sum_{j=1}^p \|\mathbf{y}_{k+j|k} - \mathbf{y}_{sp,k} + \Delta \mathbf{y}_k\|_{\mathbf{Q}}^2 + \sum_{j=0}^{m-1} \|\Delta \mathbf{u}_{k+j|k}\|_{\mathbf{R}}^2, \quad (3)$$

sujeito a:

$$\mathbf{u}_{\min,k} \leq \mathbf{u}_{k+j|k} \leq \mathbf{u}_{\max,k}, \quad j = 0, \dots, m-1 \quad (4)$$

$$\Delta \mathbf{u}_{\min,k} \leq \Delta \mathbf{u}_{k+j|k} \leq \Delta \mathbf{u}_{\max,k}, \quad j = 0, \dots, m-1 \quad (5)$$

$$\mathbf{y}_{\min,k} \leq \mathbf{y}_{k+j|k} + \Delta \mathbf{y}_k \leq \mathbf{y}_{\max,k}, \quad j = 0, \dots, p \quad (6)$$

$$\mathbf{y}_{k+j|k} = \mathbf{g}(\mathbf{y}_k, \mathbf{y}_{k-1}, \mathbf{y}_{k-2}, \mathbf{u}_k, \mathbf{u}_{k-1}, \mathbf{u}_{k-2}), \quad j = 0, \dots, p \quad (7)$$

Neste trabalho, o horizonte de predição é representado por p , e o horizonte de controle por m . A variável $\mathbf{y}_{k+j|k}$ corresponde às saídas controladas (P_P e \dot{m}) previstas pela PIRNN, representada por \mathbf{g} , no instante $k + j$, com base nas informações de $k, k-1, k-2$. Já $\mathbf{u}_{k+j|k}$ representa as entradas manipuladas (α e N) ao longo do horizonte, enquanto $\Delta \mathbf{u}_{k+j|k}$ são os sinais de controle aplicados. O vetor $\mathbf{y}_{sp,k}$ refere-se ao set-point, e \mathbf{Q} e \mathbf{R} são as matrizes de peso das saídas e entradas, respectivamente. A variável $\Delta \mathbf{y}_k$ corrige o desvio entre a planta real e o modelo, garantindo controle sem erro em regime permanente.



Conforme Meira et al. (2022), a restrição inferior da vazão mássica, \dot{m} , segue uma função $S(\phi)$ que mapeia uma margem de segurança do surge do compressor. Essa restrição dinâmica é adotada com o objetivo de testar a capacidade do controlador de operar próximo de limites críticos. A linha de surge representa a fronteira de estabilidade do compressor, sendo associada a possíveis falhas operacionais. Por esse motivo, é adotada uma margem de segurança como restrição do controlador, para evitar que o compressor entre em surge.

As restrições e configurações adotadas no RNN-MPC e NMPC durante as simulações estão resumidas na Tabela 2.

Tabela 2: Restrições e configurações dos controladores.

Restrições dos controladores		Configurações dos controladores		
Restrição	Valores	Parâmetro	RNN-MPC	NMPC
$\mathbf{y}_{\min,k} [S(\phi) \text{ kg/s}, 5.27 \text{ MPa}]^T$		p	12	12
$\mathbf{y}_{\max,k} [12.3 \text{ kg/s}, 9.3 \text{ MPa}]^T$		m	3	3
$\mathbf{u}_{\min,k} [35\%, 450 \text{ Hz}]^T$		\mathbf{Q}	$diag([6 \cdot 10^{-3}, 1 \cdot 10^{-4}])$	$diag([6 \cdot 10^{-3}, 6 \cdot 10^{-4}])$
$\mathbf{u}_{\max,k} [65\%, 833 \text{ Hz}]^T$		\mathbf{R}	$diag([4 \cdot 10^{-6}, 2 \cdot 10^{-12}])$	$diag([4 \cdot 10^{-5}, 2 \cdot 10^{-12}])$
$\Delta\mathbf{u}_{\max,k} [10\%, 42 \text{ Hz}]^T$				

A otimização do problema foi resolvida usando o framework CasADi (ANDERSSON et al., 2018), com o solucionador IPOPT. As simulações foram realizadas em um computador com processador Intel Core i7-12700 (2.1 GHz) e 16 GB de RAM.

5 RESULTADOS E DISCUSSÃO

Para avaliar o controlador, foi escolhido um período de amostragem de 0.5 s, conforme o estudo de Meira et al. (2022). A simulação permanece 5 s em estado estacionário e ocorrem 3 variações de set-point próximas à restrição de surge, com 20 s de duração cada (tempo suficiente para análise da dinâmica e do estado estacionário), totalizando 65 s. Para comparação, utilizou-se um NMPC nominal com modelo fenomenológico e integração numérica tradicional pelo CasADi. Os resultados estão representados nas Figuras 3 e 4, nos quais se observa comportamento oscilatório em ambos os controladores, especialmente na pressão.

Figura 3: Vazão x Tempo.

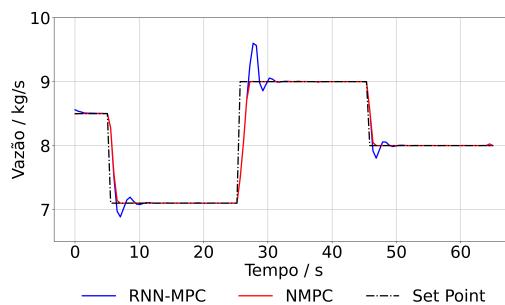
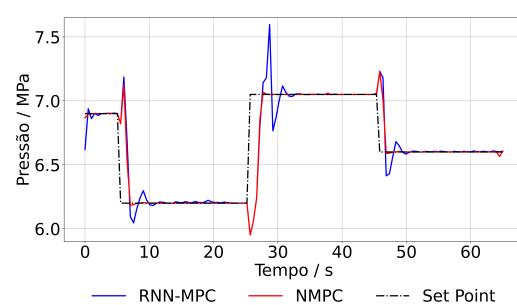


Figura 4: Pressão x Tempo.



Na Figura 5 é possível observar a distância entre a vazão e a margem de segurança do compressor, caso a distância seja menor que 0, a margem de segurança seria violada. A trajetória da vazão mássica e razão de compressor, com a restrição de surge, é representada pela Figura 6.



Figura 5: Distância à margem de segurança.

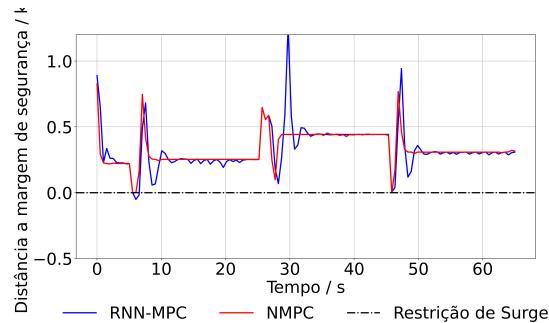
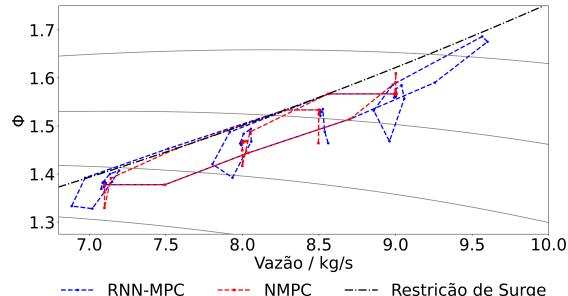


Figura 6: Trajetória do compressor.



Em ambos os controladores, observa-se controle estável do sistema para todos os set-points. Porém, RNN-MPC viola a restrição no instante de tempo 5 s a 7 s, no instante 8 s ele volta a obedecer a restrição, como visto na Figura 5. As oscilações ocorrem devido ao esforço de controle necessário para não infringir a restrição de surge.

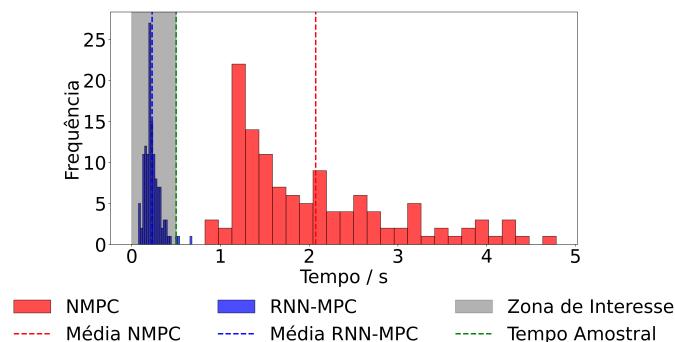
A Tabela 3 apresenta o ISE (*Integral Squared Error*) das variáveis controladas, para avaliar o desvio entre o resultado do controlador e o set-point, e o ISDMV (*Integrated Squared Difference of Manipulated Variables*) das variáveis manipuladas, para avaliar o esforço do sinal de controle.

Tabela 3: ISE e ISDMV.

Indicadores	Equação	RNN-MPC	NMPC	Discrepância percentual
ISE - Vazão	$\int (\dot{m}_{sp} - \dot{m})^2 dt$	$1.95 \cdot 10^4$	$1.89 \cdot 10^4$	2.89%
ISE - Pressão	$\int (\mathbf{P}_{P_{sp}} - \mathbf{P}_P)^2 dt$	$4.17 \cdot 10^3$	$4.04 \cdot 10^3$	3.09%
ISDMV - Válvula	$\int \Delta \alpha^2 dt$	$7.10 \cdot 10^2$	$3.90 \cdot 10^2$	82.31%
ISDMV - Vel. Rotação	$\int \Delta N^2 dt$	$9.42 \cdot 10^7$	$5.73 \cdot 10^7$	64.44%

Nos 65 s simulados, ocorreram 130 passos de amostragem. A quantidade de tempo para resolução de cada passo está representado na Figura 7.

Figura 7: Histograma de tempos de solução.



A simulação do RNN-MPC teve tempo médio de 0.31 s, inferior ao tempo de amostragem do sistema, enquanto o NMPC nominal levou 2.66 s. Apesar do melhor desempenho, o NMPC



é inviável para controle em tempo real devido ao tempo de cômputo superior ao tempo de amostragem. Já o RNN-MPC, cerca de 8.65 vezes mais rápido, mostra-se viável para implementação em tempo real. Seu desempenho foi próximo ao do NMPC nas variáveis controladas, apresentando desvio médio em torno de 3%, o que é aceitável em muitas aplicações. No entanto, o controlador apresentou desempenho inferior nas variáveis manipuladas, com maiores oscilações e esforço de controle, como detalhado na Tabela 3.

6 CONCLUSÃO

O RNN-MPC apresentou tempo de cômputo compatível com a implementação em tempo real, com desempenho nas variáveis controladas próximo à de um NMPC, embora apresente maior esforço de controle. O uso de redes neurais em controladores MPC demonstrou-se eficaz em aplicações que exigem respostas rápidas. Entretanto, o desempenho do RNN-MPC deixa claro que ainda há necessidade de refinamento. Esse refinamento pode ser melhorado por meio de métodos eficientes de sintonia do controlador. Como tema de trabalhos futuros será investigado o desempenho do controlador RNN-MPC e a sua aplicação em sistemas mais complexos.

7 AGRADECIMENTOS

Agradecimento ao apoio financeiro do Programa de Recursos Humanos da Agência Nacional do Petróleo, Gás e Biocombustíveis (PRH/ANP - PRH35.1/UFBA), suportado com recursos provenientes do investimento de empresas petrolíferas qualificadas na Cláusula de PD&I da Resolução ANP nº 50/2015 e da Fundação de Amparo à Pesquisa do Estado de São Paulo (FAPESP), processo nº 2024/10318-2. Agradecimentos também à Escola Politécnica da Universidade Federal da Bahia pelo suporte institucional e pela infraestrutura física disponibilizada e ao Programa jovem doutor pelo apoio.

8 REFERÊNCIAS

- ANDERSSON, J. et al. Casadi: a software framework for nonlinear optimization and optimal control. *Mathematical Programming Computation*, v. 11, 07 2018.
- DRAEGER, A.; ENGELL, S.; RANKE, H. Model predictive control using neural networks. *Control Systems, IEEE*, v. 15, p. 61 – 66, 11 1995.
- MEIRA, R. L. *Rigorous dynamic modeling and predictive control of compressible fluid transport systems integrated with centrifugal compressors*. Tese (Doutorado) — Universidade Federal da Bahia, 2022.
- MEIRA, R. L. et al. Implementable mpc-based surge avoidance nonlinear control strategies for non-ideally modeled natural gas compression systems. *Journal of Natural Gas Science and Engineering*, v. 102, p. 104573, 2022. ISSN 1875-5100.
- NASCIMENTO, C.; GIUDICI, R.; GUARDANI, R. Neural network based approach for optimization of industrial chemical processes. *Computers Chemical Engineering*, v. 24, p. 2303–2314, 10 2000.