

# REDES NEURAIS ARTIFICIAIS RECORRENTES APLICADAS A MODELOS DINÂMICOS DE SISTEMAS DE COMPRESSÃO DE GÁS NATURAL

GUILHERME S. FREIRE, MATHEUS M. BEZERRA, RODRIGO L. MEIRA, LEONARDO S. DE SOUZA, MÁRCIO A. F. MARTINS

**Resumo**— A inserção de Redes Neurais Artificiais (RNA) em processos industriais para a previsão confiável de futuros estados se demonstra como uma ferramenta robusta (NASCIMENTO; GIUDICI; GUARDANI, 2000), pois com elas é possível trabalhar apenas utilizando de uma coleta de dados consistente. As RNA's conseguem se adaptar à natureza do sistema, independente da sua não linearidade, ademais existe a possibilidade de aumento da complexidade do sistema sem muitas dificuldades. Uma vez adaptadas ao comportamento do processo, as RNA's conseguem efetuar previsões rapidamente, com baixo custo computacional e com alta confiabilidade se comparado aos métodos numéricos para integração de equações diferenciais resultantes da abordagem fenomenológica de modelagem de sistemas dinâmicos. Neste trabalho foi criada uma RNA para prever futuros estados de um modelo para descrever a dinâmica de um sistema de compressão de gás natural (MEIRA et al., 2022), por conta da natureza altamente oscilatória do sistema e a necessidade de previsão desse comportamento. Para isso, foi utilizada uma arquitetura de RNA recorrente em busca de menor tempo de cômputo e menor custo operacional, os resultados foram comparados com a resposta de um método numérico baseado no fenômeno de modelagem do sistema, utilizando a biblioteca open-source CasADi.

**Palavras-chave**— Gás Natural, Rede Neural Artificial, Previsão, Sistema de Compressão, Modelos não-ideais

## 1 Introdução

A previsão de futuros estados de processos industriais, especialmente na área da engenharia química, permite um controle eficiente do processo, evitando problemas futuros como, por exemplo, falhas em equipamentos, queda na produção, aumento do consumo de energia, entre outros. Entretanto, para obter uma previsão de alta confiabilidade, é necessário, primeiramente, dispor de uma modelagem eficiente do processo. Esses modelos, muitas vezes, apresentam alta complexidade e demandam um elevado tempo de processamento para serem aplicados aos sistemas de controle.

As Redes Neurais Artificiais (RNA) são poderosas ferramentas que, no âmbito industrial, permitem o uso exclusivo de dados para a previsão de sistemas complexos e não lineares. As RNAs podem ser utilizadas como modelos substitutos para contornar os desafios relacionados à redução do tempo de processamento, mantendo, ainda assim, uma boa confiabilidade. Nascimento, Giudici e Guardani (2000) destacam a aplicação de RNAs na indústria, exemplificando sua utilização na otimização e modelagem do processo de polimerização do nylon-6,6, além da minimização da geração de subprodutos em plantas de produção de anidrido acético bruto.

Este trabalho busca implementar uma arquitetura de RNA recorrente como modelo substituto para prever o comportamento do modelo de compressor centrífugo axial de Moore e Greitzer (1986). Os dados serão gerados por métodos numéricos de integração baseados na modelagem fenomenológica do sistema, sendo posteriormente utilizados para o treinamento da rede. Por fim, as previsões obtidas serão comparadas com as previsões do método numérico, visando alcançar maior confiabilidade e menor tempo de processamento.

## 2 O Sistema

### 2.1 Sistema de Compressão




Figura 1: Sistema de Compressão

O sistema de compressão descrito é composto por um compressor centrífugo, um duto e um plenum. As equações comumente adotadas na literatura para esse sistema (MEIRA et al., 2022), baseadas no momento angular axial, no balanço de momento do duto e na combinação do balanço de massa e energia do plenum, são apresentadas a seguir:

$$\frac{d\dot{m}}{dt} = \frac{A_1}{L_C} (\phi(N(t), \dot{m}) P_1 - P_P(t)) \quad (1)$$

$$\frac{dP_P}{dt} = \frac{C_1^2}{v_P} (\dot{m}(t) - \alpha(t) K_\nu \sqrt{P_P - P_{out}}) \quad (2)$$

A Equação 1 representa o balanço de momento, enquanto a Equação 2 descreve o balanço politrópico. Nelas,  $\dot{m}$  é a vazão do compressor,  $P_P$  é a pressão do plenum,  $\phi$  é a razão entre as pressões de entrada e saída do compressor, definida como uma função de  $\dot{m}$  e da velocidade rotacional do compressor  $N$ ,  $P_1$  é a pressão de entrada do

compressor,  $P_{out}$  é a pressão de saída da válvula,  $\alpha$  é a abertura da válvula,  $K_v$  é o coeficiente da válvula,  $A_1$  é a área do duto,  $L_C$  é o comprimento do duto,  $v_P$  é o volume do plenum e  $C_1$  é a velocidade do som no gás de entrada. A Tabela 1 apresenta os valores e as unidades das constantes do sistema.

Variável	Valor	Unidade
$A_1$	$2.6 \times 10^{-3}$	$m^2$
$v_P$	2.0	$m^3$
$L_C$	2.0	m
$k_v$	0.38	$kg\ s^{-1}\ (kPa)^{-0.5}$
$T_1$	300	K
$P_1$	8.5	MPa
$P_{out}$	5.0	MPa

Tabela 1: Tabela de variáveis com suas unidades e valores.

Alterações nas variáveis manipuladas, como a abertura da válvula ( $\alpha$ ) e a velocidade rotacional do compressor ( $N$ ), impactam diretamente a pressão do plenum ( $P_P$ ). Esses efeitos são ilustrados nas Figuras 2 e 3.




Figura 2: Pressão com mudança na abertura da válvula




Figura 3: Pressão com mudança na velocidade rotacional

## 2.2 Rede Neural Artificial

A otimização em processos industriais caracteriza-se pela busca da configuração mais eficiente para um determinado objetivo, evitando perdas e respeitando as condições restritivas. Os métodos de otimização permitem refinar os sistemas de simulação a cada iteração, fornecendo um retorno (*feedback*) sobre a proximidade com os resultados esperados e realizando as modificações necessárias na simulação. Nas RNAs, os otimizadores mais utilizados são os "Métodos de Procura Baseados no Gradiente", como, por exemplo, o ADAM. As alterações induzidas por esses métodos ocorrem nos pesos e nos *bias* da rede.

A Figura 4 apresenta um diagrama de uma RNA simples, com duas entradas  $x_1$  e  $x_2$  e uma saída  $y$ . A rede também possui duas camadas escondidas.




Figura 4: RNA Simples

$$i_j^l = \sigma \left( \sum_k w_{jk}^l i_k^{l-1} + b_j^l \right) \quad (3)$$

As entradas  $i$  do neurônio  $j$  na camada  $l$  são obtidas pela passagem das entradas da camada anterior. Essas entradas passam pelas camadas escondidas, seguindo a Equação 3, que representa a soma de todos os  $k$  neurônios na camada  $l-1$ . Os parâmetros otimizados são os pesos  $w^l$  e os *bias*  $b^l$ . Cada camada da rede utiliza uma função de ativação  $\sigma$ , que pode ser reescrita como na Equação 4:

$$i^l = \sigma (w^l i^{l-1} + b^l) \quad (4)$$

Para otimizar os parâmetros, as redes neurais utilizam o método de *backpropagation*, que avalia a relevância de cada parâmetro para a função de custo da RNA (Equação 5):

$$C = \frac{1}{2n} \sum_{x=1}^n ||y(x) - i^L(x)||^2 \quad (5)$$

Nessa equação,  $n$  é o número de dados de treino  $x$ ,  $y(x)$  é a saída desejada e  $i^L(x)$  é a saída da última camada  $L$ . A função de custo pode ser adaptada conforme a necessidade de cada

RNA. Por exemplo, em *Physics Informed Neural Networks* (PINNs) (CAI et al., 2021), a função de custo também considera o fenômeno físico relacionado ao objetivo da rede.

Conforme Nielsen (2019), as seguintes equações principais são utilizadas para determinar o ajuste necessário de cada parâmetro:

$$\delta^L = \nabla_a C \odot \sigma'(z^L) \quad (6)$$

$$\delta^l = \left( (w^{l+1})^T \delta^{l+1} \right) \odot \sigma'(z^l) \quad (7)$$

$$\frac{\partial C}{\partial b_j^l} = \delta_j^l \quad (8)$$

$$\frac{\partial C}{\partial w_{jk}^l} = i_k^{l-1} \delta_j^l \quad (9)$$

Com as derivadas parciais da função de custo, é possível determinar as modificações necessárias para minimizar a função. Para isso, define-se o valor  $\delta_j^l$ , que representa o erro associado ao neurônio  $j$  na camada  $l$ , sendo  $z$  a saída do neurônio com o erro. A Equação 6 calcula o erro na camada de saída, enquanto a Equação 7 determina o erro da camada  $l$  com base na camada  $l+1$ . Já as Equações 8 e 9 fornecem, respectivamente, as derivadas do custo em relação aos *bias* e aos pesos de cada camada.

As redes neurais também podem ser utilizadas para prever situações futuras em sistemas. Redes Neurais Recorrentes (RNNs) são alimentadas com dados que variam no tempo (i.e.,  $\mathbf{X}_{t-1}$  e  $\mathbf{X}_t$ ) para prever dados futuros (i.e.,  $\mathbf{X}_{t+1}$ ). A Figura 5 ilustra esse tipo de rede neural, sendo  $\mathbf{x}$  os dados de entrada,  $\mathbf{h}$  os dados de saída,  $\mathbf{o}$  a função de perda e  $\mathbf{U}, \mathbf{V}, \mathbf{W}$  os pesos.




Figura 5: Exemplo de RNA Recorrente

A RNA utilizada neste trabalho é composta por uma camada de normalização dos dados, uma camada recorrente, duas camadas densas e uma última camada de desnormalização, conforme ilustrado na Figura 6:




Figura 6: Arquitetura de RNA utilizada

A RNA possui 60 neurônios em cada camada densa. O treinamento foi realizado com 5000 *epochs*, utilizando o otimizador ADAM com uma taxa de aprendizado (*learning rate*) de  $10^{-6}$ , alcançando uma perda (*loss*) mínima de 0,41.

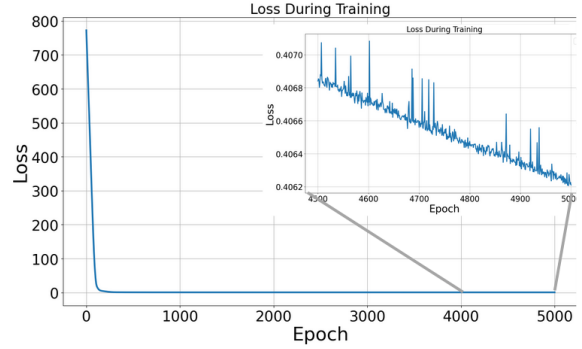


Figura 7: Evolução da Função Loss

As entradas de vazão, pressão do plenum, abertura da válvula, velocidade de rotação do compressor e desvios  $\beta$  são representadas na Tabela 2.

	$\dot{m}/\frac{Kg}{s}$	$P_P/MPa$	$\alpha/\%$	$N/hz$
Min	3.5	5.27	35	27000
Max	12.3	10.33	65	50000
$\beta$	-	-	0,5	1000

Tabela 2: Domínio e unidades das variáveis de entrada

A camada recorrente segue a arquitetura Long-Short Term Memory (LSTM). Essa abordagem é utilizada para prever futuros estados do sistema, pois possui a capacidade de lembrar valores em intervalos arbitrários. A LSTM é dividida em três portões: *Forget Gate*, onde informações não úteis ao estado da célula são removidas; *Input Gate*, onde informações úteis são adicionadas ao estado da célula; e *Output Gate*, que extrai informações relevantes para serem apresentadas como saídas.

### 3 Método

Os dados de treinamento da RNA recorrente utilizada foram gerados a partir de um método numérico de integração baseado no modelo fenomenológico do sistema, que simulou 3000 segundos, utilizando a biblioteca open-source CasADi. Esses dados foram enviados em pacotes de 3 *time-steps* ( $\mathbf{X}_{t-2}, \mathbf{X}_{t-1}, \mathbf{X}_t$ ), com um espaço amostral de 0,1 segundos, para prever o futuro estado do sistema ( $\mathbf{X}_{t+1}$ ), que também foi fornecido à rede para comparação e cálculo do erro relativo.

Durante a simulação do modelo, as variáveis manipuladas — abertura da válvula ( $\alpha$ ) e velocidade rotacional do compressor ( $N$ ) — foram alteradas aleatoriamente dentro do domínio já apresentado a cada 100 segundos, promovendo perturbações constantes no sistema.

O resultado do treinamento é um modelo de RNA com todos os pesos e *bias* estabelecidos. Na fase de teste, foi fornecido apenas um conjunto de 3 *timesteps* para a rede, que realizou a previsão do comportamento do sistema durante 700 segundos. Consequentemente, as previsões obtidas também incorporaram o erro acumulado das previsões anteriores. Esse mesmo procedimento foi repetido várias vezes para comparar o tempo médio de solução e a precisão de diferentes modelos.

## 4 Resultados

As soluções de vazão mássica e pressão do plenum encontradas podem ser observadas, respectivamente, na Figura 8 e na Figura 9. Com tais soluções, é possível observar alta similaridade entre os resultados dos modelos de solução numérica e da solução utilizando a RNA.




Figura 8: Vazão X Tempo




Figura 9: Pressão X Tempo

Foram efetuados 325 exemplos diferentes para criar uma comparação da velocidade de soluções, onde foram obtidas velocidades médias de 0,22 segundos utilizando o método numérico com a biblioteca CasADi e 0,04 segundos utilizando o método substituto feito com a RNA. A velocidade de solução de cada exemplo está apresentada na Figura 10.




Figura 10: Comparação de velocidade de soluções

## 5 Conclusão

A utilização de Redes Neurais Artificiais (RNAs) em aplicações práticas tem demonstrado vantagens significativas quando comparada a métodos tradicionais, como os modelos de integração numérica comuns. Um dos pontos mais destacados é a eficiência em termos de tempo de processamento. Em média, o modelo baseado em RNA foi aproximadamente cinco vezes mais rápido do que os métodos convencionais. Essa diferença de desempenho é particularmente relevante em cenários onde a rapidez na obtenção de resultados é crucial, como na análise de dados em tempo real ou em sistemas que demandam respostas rápidas.

Além da questão do tempo, as RNAs também se mostram mais econômicas no uso de recursos computacionais. Isso significa que, para realizar cálculos de complexidade equivalente, o modelo de RNA exige menor capacidade de processamento e memória. Essa característica é especialmente importante em contextos onde há restrições de hardware ou quando o objetivo é reduzir custos operacionais. A economia de recursos permite que as RNAs sejam aplicadas de forma eficaz em dispositivos com capacidades limitadas, como sistemas embarcados ou equipamentos móveis.

Outro aspecto que reforça a vantagem do uso de RNAs é sua aplicabilidade em problemas de alta dimensionalidade ou em situações onde os modelos fenomenológicos ainda não foram desenvolvidos. Os modelos fenomenológicos, frequentemente baseados em equações diferenciais ou representações matemáticas detalhadas, demandam um entendimento profundo dos fenômenos físicos ou químicos subjacentes. No entanto, quando esses modelos não estão disponíveis ou são excessivamente complexos para serem desenvolvidos em um prazo viável, as RNAs oferecem uma alternativa poderosa. Elas conseguem aprender padrões diretamente dos dados, sem a necessidade de modelagem explícita. Isso as torna ideais para problemas multidimensionais ou para áreas onde os dados são abundantes, mas o conhecimento teórico ainda é limitado.

Em síntese, as Redes Neurais Artificiais destacam-se não apenas por sua rapidez e efici-

ência no uso de recursos, mas também por sua adaptabilidade a diferentes contextos. Sua aplicabilidade se torna ainda mais evidente em cenários onde há alta complexidade ou falta de modelos pré-estabelecidos, reforçando seu papel como uma ferramenta indispensável para a resolução de problemas modernos.

### Referências

CAI, S. et al. Physics-informed neural networks (pinns) for fluid mechanics: a review. *Acta Mechanica Sinica*, p. 1727–1738, 12 2021.

MEIRA, R. L. et al. Implementable mpc-based surge avoidance nonlinear control strategies for non-ideally modeled natural gas compression systems. *Journal of Natural Gas Science and Engineering*, v. 102, p. 104573, 2022. ISSN 1875-5100. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S1875510022001627>>.

MOORE, F. K.; GREITZER, E. M. A theory of post-stall transients in axial compression systems: Part i—development of equations. *Journal of Engineering for Gas Turbines and Power*, v. 108, n. 1, p. 68–76, 01 1986. ISSN 0742-4795. Disponível em: <<https://doi.org/10.1115/1.3239887>>.

NASCIMENTO, C. A. O.; GIUDICI, R.; GUARDANI, R. Neural network based approach for optimization of industrial chemical processes. *Computers Chemical Engineering*, v. 24, n. 9, p. 2303–2314, 2000. ISSN 0098-1354. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0098135400005871>>.

NIELSEN, M. *Neural Networks and Deep Learning*. [s.n.], 2019. Disponível em: <<http://neuralnetworksanddeeplearning.com>>.